

Universidade Federal do Rio de Janeiro
Instituto Alberto Luiz Coimbra de
Pós-Graduação e Pesquisa de Engenharia



Programa de Engenharia de Sistemas e
Computação

CPS767 - Algoritmos de Monte Carlo e Cadeias de Markov
Prof. Daniel Ratton Figueiredo

2ª Lista de Exercícios

Luiz Henrique Souza Caldas
email: lhscaldas@cos.ufrj.br

4 de abril de 2025

Questão 1: Cauda do dado

Considere um icosaedro (um sólido Platônico de 20 faces) honesto, tal que a probabilidade associada a cada face é $1/20$. Considere que o dado será lançado até que um número primo seja observado, e seja Z a variável aleatória que denota o número de vezes que o dado é lançado. Responda às perguntas abaixo:

1. Determine a distribuição de Z , ou seja $P[Z = k]$, $k = 1, 2, \dots$. Que distribuição é esta?

Resposta:

Os números primos são 2, 3, 5, 7, 11, 13, 17, 19. Portanto, a probabilidade de obter um número primo em um lançamento é $p = \frac{8}{20} = \frac{2}{5}$. Consequentemente, a probabilidade de não obter um número primo em um lançamento é $1 - p = \frac{3}{5}$. Assim, a distribuição de Z é dada por:

$$P[Z = k] = (1 - p)^{k-1} p = \left(\frac{3}{5}\right)^{k-1} \left(\frac{2}{5}\right)$$

para $k = 1, 2, \dots$. Esta é uma distribuição geométrica com parâmetro $p = \frac{2}{5}$.

2. Utilize a desigualdade de Markov para calcular um limitante para $P[Z \geq 10]$.

Resposta:

A desigualdade de Markov afirma que, para uma v.a. $Z > 0$ e $a > 0$, temos:

$$P[Z \geq a] \leq \frac{E[Z]}{a}$$

Para calcular $E[Z]$, utilizamos a fórmula da média de uma distribuição geométrica:

$$E[Z] = \frac{1}{p} = \frac{1}{\frac{2}{5}} = \frac{5}{2}$$

Assim, aplicando a desigualdade de Markov com $a = 10$, obtemos:

$$P[Z \geq 10] \leq \frac{E[Z]}{10} = \frac{\frac{5}{2}}{10} = \frac{1}{4} = 0.25$$

Portanto, $P[Z \geq 10] \leq 0.25$. Isso significa que a probabilidade de o número de lançamentos do dado ser maior ou igual a 10 é menor ou igual a 25%.

3. Utilize a desigualdade de Chebyshev para calcular um limitante para $P[Z \geq 10]$.

Resposta:

A média e variância da distribuição geométrica são $\mu = \frac{1}{p} = \frac{5}{2}$ e $\sigma^2 = \frac{1-p}{p^2} = \frac{15}{4}$.
Aplicando Chebyshev:

$$P[|Z - \mu| \geq k\sigma] \leq \frac{1}{k^2}$$

Subtraindo μ de ambos os lados em $P[Z \geq 10]$, temos:

$$P[Z \geq 10] = P[Z - \mu \geq 10 - \frac{5}{2}] = P[Z - \mu \geq \frac{15}{2}] \leq P[|Z - \mu| \geq k\sigma]$$

Fazendo $k\sigma = \frac{15}{2}$, então

$$k = \frac{15}{2} \cdot \frac{2}{\sqrt{15}} = \sqrt{15}$$

Assim, temos:

$$P[Z \geq 10] \leq \frac{1}{15} \approx 0.0667$$

4. Calcule o valor exato de $P[Z \geq 10]$ (dica: use probabilidade complementar). Compare os valores obtidos.

Resposta:

$$P[Z \geq 10] = 1 - P[Z \leq 9] = 1 - \sum_{k=1}^9 P[Z = k]$$

$$P[Z \geq 10] = 1 - \frac{2}{5} \sum_{k=1}^9 \left(\frac{3}{5}\right)^{k-1} = 1 - \frac{2}{5} \cdot \frac{1 - \left(\frac{3}{5}\right)^9}{1 - \frac{3}{5}} = \left(\frac{3}{5}\right)^9$$

$$P[Z \geq 10] = \left(\frac{3}{5}\right)^9 \approx 0,0101$$

Comparando os valores:

- Markov: $P[Z \geq 10] \leq 0,25$
- Chebyshev: $P[Z \geq 10] \leq 0,0667$
- Valor exato: $P[Z \geq 10] \approx 0,0101$

Ambas as desigualdades fornecem limites conservadores, sendo Chebyshev mais ajustado que Markov. O valor exato é o mais preciso.

Questão 2: Pesquisa eleitoral

Você leu no jornal que uma pesquisa eleitoral com 1500 pessoas indicou que 40% dos entrevistados prefere o candidato A enquanto 60% preferem o candidato B. Determine a margem de erro desta pesquisa usando uma confiança de 95%. O que você precisou assumir para calcular a margem de erro?

Resposta:

Seja X_i uma variável aleatória i.i.d. que representa a preferência do entrevistado i , com:

$$X_i = \begin{cases} 1 & \text{se prefere o candidato A} \\ 0 & \text{se prefere o candidato B} \end{cases}$$

A média amostral de X_i é dada por:

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i = 0.4$$

Como $E[M_n] = \mu$, onde $\mu = p$ é a média da distribuição de Bernoulli, temos, pela desigualdade de Chebyshev:

$$P[|M_n - p| \geq k\sigma_{M_n}] \leq \frac{1}{k^2}$$

onde $\sigma_{M_n} = \sqrt{\frac{\sigma^2}{n}}$ é o desvio padrão da média amostral, sendo $\sigma^2 = p(1-p)$ a variância da distribuição de Bernoulli.

Fazendo a margem de erro $\epsilon = k\sigma_{M_n}$, temos:

$$k = \frac{\epsilon}{\sigma_{M_n}} = \frac{\epsilon\sqrt{n}}{\sigma} \Rightarrow P[|M_n - p| \geq \epsilon] \leq \frac{\sigma^2}{\epsilon^2 n}$$

Aplicando o complementar, temos:

$$P[|M_n - p| < \epsilon] = 1 - P[|M_n - p| \geq \epsilon] \geq 1 - \frac{\sigma^2}{\epsilon^2 n} = \beta$$

onde β é o nível de confiança que queremos.

Resolvendo para ϵ :

$$\epsilon = \sqrt{\frac{\sigma^2}{(1-\beta)n}} = \sqrt{\frac{p(1-p)}{(1-\beta)n}}$$

Assumindo que n é grande o suficiente para $M_n = \mu = p = 0.4$, temos:

$$\epsilon = \sqrt{\frac{0.4(1-0.4)}{(1-0.95)1500}} = \sqrt{\frac{0.4(0.6)}{0.05 \cdot 1500}} = \sqrt{\frac{0.24}{75}} = \sqrt{0.0032} \approx \underline{0.0565}$$

Questão 3: Sanduíches

Você convidou 64 pessoas para uma festa e agora precisa preparar sanduíches para os convidados. Você acredita que cada convidado irá comer 0, 1 ou 2 sanduíches com probabilidades $1/4$, $1/2$ e $1/4$, respectivamente. Assuma que o número de sanduíches que cada convidado irá comer é independente de qualquer outro convidado. Quantos sanduíches você deve preparar para ter uma confiança de 95% de que não vai faltar sanduíches para os convidados?

Resposta:

Seja X_i a variável aleatória que representa o número de sanduíches que o convidado i irá comer, com distribuição de probabilidade dada por:

$$p_i = \begin{cases} \frac{1}{4} & \text{se } i = 0 \\ \frac{1}{2} & \text{se } i = 1 \\ \frac{1}{4} & \text{se } i = 2 \end{cases}$$

O valor esperado de X_i é dado por:

$$E[X_i] = \sum_{i=0}^2 i \cdot p_i = 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} = 0 + \frac{1}{2} + \frac{2}{4} = 1$$

A variância de X_i é dada por:

$$E[X_i^2] = \sum_{i=0}^2 i^2 \cdot p_i = 0^2 \cdot \frac{1}{4} + 1^2 \cdot \frac{1}{2} + 2^2 \cdot \frac{1}{4} = 0 + \frac{1}{2} + \frac{4}{4} = 0 + \frac{1}{2} + 1 = \frac{3}{2}$$

$$Var[X_i] = E[X_i^2] - (E[X_i])^2 = \frac{3}{2} - 1^2 = \frac{3}{2} - 1 = \frac{1}{2}$$

Questão 4: Graus improváveis

Considere o modelo de grafo aleatório de Erdős-Rényi (também conhecido por $G(n, p)$), onde cada possível aresta de um grafo rotulado com n vértices ocorre com probabilidade p , independentemente. Responda às perguntas abaixo:

1. Determine a distribuição do grau do vértice 1 (em função de n e p).

Resposta:

2. Determine o valor γ (em função de n e p) tal que com alta probabilidade $(1 - 1/n)$ o grau observado no vértice 1 é menor ou igual a γ .

Resposta:

Questão 5: Calculando uma importante constante

Seja X_i uma sequência i.i.d. de v.a. contínuas uniformes em $[0, 1]$. Seja V o menor número k tal que a soma das primeiras k variáveis seja maior do que 1. Ou seja, $V = \min\{k \mid X_1 + \dots + X_k \geq 1\}$.

1. Escreva e implemente um algoritmo para gerar uma amostra de V .

Resposta:

- Pseudo-código:

```
soma = 0;
contador = 0;
enquanto soma < 1 faça
    x = amostra de U[0, 1];
    soma = soma + x;
    contador = contador + 1;
retorne contador;
```

- Implementação em Python:

```
1  def amostra_V():
2      soma = 0
3      contador = 0
4      while soma < 1:
5          x = random()
6          soma += x
7          contador += 1
8      return contador
```

2. Escreva e implemente um algoritmo de Monte Carlo para estimar o valor esperado de V .

Resposta:

- Definição do estimador: Pela Lei dos Grandes Números, temos que, para n suficientemente grande, a média amostral converge para o valor esperado:

$$E[V] \approx \frac{1}{n} \sum_{i=1}^n V_i$$

onde V_i é a amostra de V obtida na iteração i .

- Pseudo-código:

```
n = N; // número de amostras
soma = 0;
para i = 1 até n faça
    soma = soma + amostra_V();
estimador = soma / n;
retorne estimador;
```

- Implementação em Python:

```
1  def estimador_E(n):
2      soma = 0
3      for i in range(n):
4          x = amostra_V()
5          soma += x
6      return soma / n
```

3. Trace um gráfico do valor estimado em função do número de amostras. Para qual valor seu estimador está convergindo?

Resposta:

Código para gerar o gráfico:

```
1 def grafico_E(n_max):
2
3     n_values = list(range(1, n_max + 1))
4     E_values = [estimador_E(n) for n in n_values]
5
6     plt.plot(n_values, E_values, label='E[V] a cada n')
7     label = f'Limite E[V] = {E_values[-1]}'
8     plt.axhline(y=E_values[-1], color='r', linestyle='--', label=
9         label)
10    plt.title('Estimador de E[V] em função de n')
11    plt.xlabel('n')
12    plt.ylabel('E[V]')
13    plt.grid(True)
14    plt.legend()
15    plt.show()
```

Para 10^4 amostras, o estimador converge para aproximadamente $E[V] \approx 2.7076$, como visto na figura abaixo.




Figura 1: Estimador de $E[V]$ em função de n

Questão 6: Transformada inversa

Mostre como o método da transformada inversa pode ser usado para gerar amostras de uma v.a. contínua X com as seguintes distribuições:

1. Distribuição exponencial com parâmetro $\lambda > 0$, cuja função densidade é dada por $f_X(x) = \lambda e^{-\lambda x}$, para $x \geq 0$.

Resposta:

2. Distribuição de Pareto com parâmetros $x_0 > 0$ e $\alpha > 0$, cuja função densidade é dada por $f_X(x) = \frac{\alpha x_0^\alpha}{x^{\alpha+1}}$, para $x \geq x_0$.

Resposta:

Questão 7: Contando domínios na Web

Quantos domínios web existem dentro da UFRJ? Mais precisamente, quantos domínios existem dentro do padrão de nomes `http://www.[a-z](k).ufrj.br`, onde $[a-z](k)$ é qualquer sequência de caracteres de comprimento k ou menor? Construa um algoritmo de Monte Carlo para estimar este número.

1. Descreva a variável aleatória cujo valor esperado está relacionado com a medida de interesse. Relacione analiticamente o valor esperado com a medida de interesse.

Resposta:

2. Implemente o método de Monte Carlo para gerar amostras e estimar a medida de interesse. Para determinar o valor de uma amostra, você deve consultar o domínio gerado para determinar se o mesmo existe (utilize uma biblioteca web para isto).

Resposta:

3. Assuma que $k = 4$. Seja \hat{w}_n o valor do estimador do número de domínios após n amostras. Trace um gráfico em escala semi-log (eixo- x em escala log) de \hat{w}_n em função de n para $n = 1, \dots, 10^5$ (ou mais, se conseguir). O que você pode dizer sobre a convergência de \hat{w}_n ?

Resposta:

Questão 8: Rejection Sampling

Considere o problema de gerar amostras de uma v.a. $X \sim \text{Binomial}(1000, 0.2)$.

1. Descreva uma proposta simples de função de probabilidade para gerar amostras de X usando Rejection Sampling. Calcule a eficiência dessa proposta.

Resposta:

2. Lembrando que a distribuição Binomial tem a forma de sino, centrada em sua média, proponha outra função de probabilidade para gerar amostras de X usando Rejection Sampling. Calcule a eficiência dessa proposta e compare com a eficiência acima. O que você pode concluir?

Resposta:

Questão 9: Integração de Monte Carlo e Importance Sampling

Considere a função $g(x) = e^{-x^2}$ e a integral de $g(x)$ no intervalo $[0, 1]$.

1. Implemente um método de Monte Carlo simples para estimar o valor da integral.

Resposta:

2. Intuitivamente, muitas amostras de $g(x)$ vão ter valores muito baixos. Dessa forma, utilize Importance Sampling para melhorar a qualidade do estimador do valor da integral. Em particular, utilize a função de densidade $h(x) = Ae^{-x}$ definida em $[0, 1]$ onde A é o valor da constante de normalização. Mostre como gerar amostras de $h(x)$.

Resposta:

3. Compare os dois métodos. Trace um gráfico do erro relativo de cada um dos estimadores em função do número de amostras. Ou seja, $|\hat{I}_n - I|/I$ onde I é o valor exato da integral e \hat{I}_n é o valor do estimador com n amostras, para $n = 10^1, 10^2, \dots, 10^6$.

Resposta:

Códigos

Os códigos utilizados para a resolução dos exercícios estão disponíveis no repositório do GitHub:
https://github.com/lhscaldas/CPS767_MCMC/